

Sinais e Sistemas (ES413) — CIn/UFPE

Projeto: Filtros Digitais para Processamento de Sinais Biomédicos

Entrega 2 — Filtros Avançados/Inteligentes e Dados de Teste

Conforme definido na Entrega 1, o sinal biomédico escolhido é o **eletrocardiograma (ECG)** e a classe de problemas compreende a remoção de três interferências típicas: ruído da rede elétrica (60 Hz), variação da linha de base (0,05–0,5 Hz) e ruído muscular/EMG (> 40 Hz). Os filtros convencionais já definidos foram o notch IIR Butterworth (60 Hz), o passa-alta IIR Butterworth ($f_c = 0,5$ Hz) e o passa-baixa FIR com janela de Hamming ($f_c = 40$ Hz). Esta entrega define os **modelos de filtros avançados e/ou inteligentes** que serão comparados às abordagens convencionais e formaliza os **dados de teste**.

1. Modelos de Filtros Digitais Avançados e/ou Inteligentes

1.1 Filtro Adaptativo LMS/NLMS (técnica avançada)

O cancelamento adaptativo de ruído estima e subtrai a interferência a partir de um sinal de referência, ajustando os coeficientes do filtro em tempo real pelo algoritmo *Least Mean Squares* (LMS) e sua versão normalizada (NLMS). A escolha é justificada pelo trabalho seminal de Widrow et al. (1975), que demonstra o cancelamento adaptativo da interferência de 60 Hz precisamente em sinais de ECG, e por Thakor & Zhu (1991), que estendem a técnica à remoção de variação de linha de base e artefatos musculares em ECG. Diferentemente do notch fixo, o filtro adaptativo acompanha flutuações de frequência e amplitude da rede elétrica, sendo adequado a sistemas não estacionários — limitação explícita dos filtros convencionais apontada no enunciado do projeto. A implementação é uma equação de diferenças FIR com coeficientes variantes no tempo, $w[n+1] = w[n] + \mu \cdot e[n] \cdot x[n]$, conectando-se diretamente aos conceitos de convolução e equações de diferenças do curso.

1.2 Denoising por Transformada Wavelet Discreta — DWT (técnica avançada)

A DWT decompõe o ECG em sub-bandas de aproximação e detalhe via bancos de filtros (análise multirresolução), permitindo atenuar o ruído por limiarização (*thresholding*) dos coeficientes de detalhe e remover a deriva da linha de base zerando os coeficientes de aproximação de nível mais alto. A justificativa apoia-se em Donoho (1995), que formaliza o *soft-thresholding* com garantias de quase-otimalidade, em Singh & Tiwari (2006), que investigam a seleção de wavelets-mãe ótimas para ECG (famílias Daubechies, em especial db4/db6, por sua semelhança morfológica com o complexo QRS), e em Ferdous et al. (2023) — referência do enunciado — que incluem a DWT entre as técnicas com melhor relação sinal-ruído na remoção de ruído de sinais biomédicos. Será utilizada decomposição em 8–9 níveis ($f_s = 360$ Hz) com limiar universal de Donoho.

1.3 Autoencoder Convolutacional de Denoising — CNN-DAE (técnica inteligente)

Como técnica inteligente, será implementado um *denoising autoencoder* totalmente convolutacional (FCN-DAE), treinado para reconstruir o ECG limpo a partir de janelas do sinal contaminado. A escolha é justificada por Chiang et al. (2019), que demonstram que autoencoders convolucionais superam filtros convencionais e DWT na remoção simultânea de ruídos compostos em ECG, e por Romero et al. (2021), cujo modelo DeepFilter supera abordagens clássicas na remoção de variação de linha de base. O enunciado do projeto destaca essa tendência ao citar Ferdous et al. (2023) — que comparam MLP, redes de Hopfield e CNN — e Tripathi et al. (2024). A vantagem central é tratar as três classes de ruído em um único modelo não linear, sem projeto explícito de banda; a desvantagem (necessidade de dados de treino) é mitigada pelo protocolo de contaminação controlada descrito na Seção 2. O treinamento usará pares (sinal limpo, sinal contaminado) gerados com o MIT-BIH NSTDB, função de perda MSE e validação em registros não vistos no treino.

Estudo comparativo (meta 5): as três abordagens serão comparadas entre si e com os filtros convencionais da Entrega 1 sob o mesmo protocolo experimental, usando as métricas SNR de saída/melhoria de SNR (dB), RMSE, PRD (*percentage root-mean-square difference*) e coeficiente de correlação com o sinal de referência, seguindo a metodologia de avaliação de Ferdous et al. (2023) e Chiang et al. (2019).

2. Dados para Testes (conjuntos de domínio público)

Serão utilizadas duas bases públicas e consolidadas do repositório **PhysioNet** (Goldberger et al., 2000):

Base de dados	Repositório	Papel no projeto
MIT-BIH Arrhythmia Database (mitdb): 48 registros de 30 min, 2 canais, $f_s = 360$ Hz, > 100 mil batimentos anotados (Moody & Mark, 2001).	physionet.org/content/mitdb/1.0.0/	Fonte dos sinais de ECG de referência (sinal "limpo") para filtragem e avaliação.
MIT-BIH Noise Stress Test Database (nstdb): registros reais de ruído de variação de linha de base (bw), artefato muscular (ma) e movimento de eletrodo (em), capturados com eletrodos em voluntários ativos (Moody et al., 1984).	physionet.org/content/nstdb/1.0.0/	Fonte de ruído fisiológico real para contaminação controlada dos registros do mitdb em níveis de SNR conhecidos (e.g., 0, 6, 12, 18 dB), além de senóides de 60 Hz sintetizadas para a interferência da rede.

Protocolo experimental: registros selecionados do mitdb serão tratados como sinal de referência; sobre eles serão somados, em níveis de SNR controlados, os ruídos reais do nstdb (bw, ma, em) e interferência senoidal de 60 Hz. Esse procedimento — o mesmo empregado na construção do próprio NSTDB e nos estudos de Chiang et al. (2019) e Romero et al. (2021) — permite calcular métricas objetivas de desempenho, pois o sinal limpo é conhecido. O acesso e a leitura dos dados serão feitos com o pacote *wfdb* em Python, e os filtros implementados com SciPy (`scipy.signal`), PyWavelets e TensorFlow/Keras, ferramentas alinhadas às sugeridas no enunciado.

Referências

- Chiang, H.-T., Hsieh, Y.-Y., Fu, S.-W., Hung, K.-H., Tsao, Y., & Chien, S.-Y. (2019). Noise reduction in ECG signals using fully convolutional denoising autoencoders. *IEEE Access*, 7: 60806–60813.
- Donoho, D. L. (1995). De-noising by soft-thresholding. *IEEE Transactions on Information Theory*, 41(3): 613–627.
- Ferdous, H., Jahan, S., Tabassum, F., & Islam, M. I. (2023). The performance analysis of digital filters and ANN in de-noising of speech and biomedical signal. *International Journal of Image, Graphics and Signal Processing*, 15(1): 63–78.
- Goldberger, A. L., et al. (2000). PhysioBank, PhysioToolkit, and PhysioNet: components of a new research resource for complex physiologic signals. *Circulation*, 101(23): e215–e220.
- Moody, G. B., & Mark, R. G. (2001). The impact of the MIT-BIH arrhythmia database. *IEEE Engineering in Medicine and Biology Magazine*, 20(3): 45–50.
- Moody, G. B., Muldrow, W. E., & Mark, R. G. (1984). A noise stress test for arrhythmia detectors. *Computers in Cardiology*, 11: 381–384.
- Romero, F. P., et al. (2021). DeepFilter: an ECG baseline wander removal filter using deep learning techniques. *Biomedical Signal Processing and Control*, 70: 102992.
- Singh, B. N., & Tiwari, A. K. (2006). Optimal selection of wavelet basis function applied to ECG signal denoising. *Digital Signal Processing*, 16(3): 275–287.
- Thakor, N. V., & Zhu, Y.-S. (1991). Applications of adaptive filtering to ECG analysis: noise cancellation and arrhythmia detection. *IEEE Transactions on Biomedical Engineering*, 38(8): 785–794.
- Tripathi, S. L., Balas, V. E., Mahmud, M., & Banerjee, S. (Eds.). (2024). *Machine Learning Models and Architectures for Biomedical Signal Processing*. Elsevier.
- Widrow, B., et al. (1975). Adaptive noise cancelling: principles and applications. *Proceedings of the IEEE*, 63(12): 1692–1716.