

Contents

Relatório Geral — Filtros Digitais para Processamento de Sinais Biomédicos	1
Estudo comparativo de <i>denoising</i> de ECG (convencionais × avançados × inteligente)	1
1. Objetivo	1
2. Fundamentação resumida	2
3. Metodologia experimental	2
Parte I — Filtros Convencionais	4
4.1 Notch IIR de 60 Hz	4
4.2 Passa-alta IIR Butterworth de 0,5 Hz	5
4.3 Passa-baixa FIR Hamming de 40 Hz	6
4.4 Síntese da Parte I	6
Parte II — Filtros Avançados (dados reais MIT-BIH)	7
5.1 Caso 1 — Ruído de 60 Hz (Registro 100)	7
5.2 Caso 2 — Deriva de Linha de Base / 0,2 Hz (Registro 101)	8
5.3 Caso 3 — Ruído Aleatório / Gaussiano / EMG (Registro 103)	8
5.4 Comparação geral dos avançados (SNR)	10
Parte III — Técnica Inteligente: CNN-DAE	13
6.1 Arquitetura	14
6.2 Protocolo de dados (a contribuição metodológica mais forte)	14
6.3 Treino	15
6.4 Avaliação estatística	15
6.5 O que se espera da CNN-DAE (hipótese de trabalho)	15
7. Comparação geral do projeto (convencionais × avançados × inteligente)	16
8. Conclusões e trabalhos futuros	17
9. Reprodutibilidade	17
10. Referências principais	18

Relatório Geral — Filtros Digitais para Processamento de Sinais Biomédicos

Estudo comparativo de *denoising* de ECG (convencionais × avançados × inteligente)

Disciplina: Sinais e Sistemas (ES413) — CIn/UFPE **Bases:** MIT-BIH Arrhythmia Database (mitdb) + Noise Stress Test Database (ns1db), PhysioNet **Equipe:** ES413 (Manoel L. Carvalho, Emanuell Luiz, Deoclécio)

1. Objetivo

Este relatório consolida, em um único documento, todo o estudo de filtragem digital de eletrocardiograma (ECG) realizado no projeto da disciplina ES413. O objetivo do trabalho é **projetar, implementar e comparar objetivamente** filtros digitais para a remoção das três classes de ruído tipicamente encontradas em registros clínicos de ECG:

- **Interferência da rede elétrica (60 Hz)** — *powerline noise* / EMI;
- **Variação da linha de base (0,05–0,5 Hz)** — *baseline wander*, de origem respiratória e de movimento;
- **Ruído muscular / aleatório (> 40 Hz)** — artefato mioelétrico (EMG) e ruído de banda larga.

O estudo está organizado em **três frentes complementares**, que cobrem as duas entregas da disciplina:

1. **Filtros convencionais (Entrega 1)** — notch IIR de 60 Hz, passa-alta IIR Butterworth de 0,5 Hz e passa-baixa FIR de fase linear (Hamming) de 40 Hz. Implementados como biblioteca reutilizável em src/ e validados sobre ECG real contaminado de forma controlada.
2. **Filtros avançados clássicos (Entrega 2)** — filtro adaptativo LMS/NLMS e *denoising* por Transformada Wavelet Discreta (DWT). Desenvolvidos nos notebooks (filtros, sintético, reais, resultados) e analisados sobre registros reais do MIT-BIH.

3. **Técnica inteligente (Entrega 2)** — *autoencoder* convolucional de *denoising* (CNN-DAE), um modelo não linear único, treinado de ponta a ponta para tratar **todas** as classes de ruído. Implementado como subprojeto independente em `cnn-dae/` (arquitetura, pipeline de dados, treino e avaliação estatística). Substitui a abordagem que, na versão anterior deste relatório, era apenas *prevista*.

A pergunta central que o relatório responde é: **qual classe de filtro é mais adequada a cada tipo de ruído, e por quê?** — e, no limite, **se um único modelo aprendido consegue substituir o conjunto de filtros especializados**.

2. Fundamentação resumida

Sinais discretos, DTFT e transformada-z. Um sinal amostrado $x[n]$ tem espectro dado pela DTFT, $X(e^{j\omega}) = \sum_n x[n]e^{-j\omega n}$, e é analisado no plano complexo pela transformada-z, $X(z) = \sum_n x[n]z^{-n}$, com $z = e^{j\omega}$ sobre a circunferência unitária. Polos e zeros de $H(z)$ determinam a estabilidade e a forma da resposta em frequência.

Filtros IIR e FIR. Um filtro IIR (recursivo) realimenta saídas passadas:

$$y[n] = \sum_{k=0}^M b_k x[n-k] - \sum_{k=1}^N a_k y[n-k], \quad H(z) = \frac{\sum_k b_k z^{-k}}{1 + \sum_k a_k z^{-k}}.$$

Um filtro FIR (não recursivo) depende apenas das entradas, $y[n] = \sum_{k=0}^{M-1} h[k] x[n-k]$. Quando os coeficientes são simétricos, o FIR tem **fase linear** e atraso de grupo constante de $(M-1)/2$ amostras — propriedade essencial para não distorcer as relações temporais entre as ondas P, QRS e T.

Filtros adaptativos (LMS/NLMS). O cancelamento adaptativo de ruído estima a interferência a partir de um sinal de referência correlacionado e a subtrai, ajustando os coeficientes a cada amostra:

$$y[n] = \mathbf{w}^T[n-1] \mathbf{x}[n], \quad e[n] = d[n] - y[n], \quad \mathbf{w}[n] = \mathbf{w}[n-1] + 2\mu e[n] \mathbf{x}[n].$$

O **NLMS** normaliza o passo pela energia da entrada, $\mathbf{w}[n] = \mathbf{w}[n-1] + \frac{\mu}{\|\mathbf{x}[n]\|^2 + \epsilon} e[n] \mathbf{x}[n]$, acelerando e estabilizando a convergência. A premissa fundamental é **dispor de uma referência bem correlacionada com o ruído**.

Transformada Wavelet Discreta (DWT). A DWT decompõe o ECG em sub-bandas de aproximação (baixa frequência) e detalhe (alta frequência) — análise multirresolução. O ruído é atenuado por limiarização (*soft-thresholding*) dos coeficientes de detalhe, com limiar universal de Donoho & Johnstone, $\lambda = \sigma \sqrt{2 \ln N}$ e $\sigma = \text{mediana}(|d_1|)/0,6745$. A wavelet-mãe db4 (Daubechies) é escolhida pela semelhança morfológica com o complexo QRS. **Não exige sinal de referência externo.**

Autoencoder convolucional de denoising (CNN-DAE). Um *denoising autoencoder* é uma rede neural treinada a reconstruir o sinal limpo x a partir de uma versão corrompida $\tilde{x}$, minimizando $\mathcal{L}(x, f_\theta(\tilde{x}))$ sobre muitos pares (ruidoso, limpo). Em sua forma totalmente convolucional 1-D, a rede aprende **filtros locais** (kernels) em vez de coeficientes fixos projetados à mão: um **encoder** comprime a janela de ECG por convoluções e *pooling* (extraindo uma representação cada vez mais abstrata e de menor resolução), um **bottleneck** concentra a informação essencial, e um **decoder** reconstrói o sinal por *upsampling*. Diferentemente dos filtros lineares (IIR/FIR/adaptativos), o mapeamento f_θ é **não linear e aprendido dos dados**, podendo modelar a estrutura morfológica do ECG e separar ruído de sinal mesmo quando ambos ocupam a mesma faixa de frequência — exatamente o cenário em que o passa-baixa convencional falha. Duas escolhas de projeto são centrais: (i) **conexões residuais** (saída = $F(x) + x$), que fazem a rede aprender apenas a *diferença* (o ruído) em vez do sinal inteiro; e (ii) a perda **MAE**, robusta a *outliers* (batimentos ectópicos, artefatos), preferível ao MSE para sinais com picos. Como a DWT, **não exige sinal de referência externo**; ao contrário de todos os demais, um **único modelo** atende a todos os tipos de ruído.

3. Metodologia experimental

3.1 Dados

Todos os sinais vêm do PhysioNet, lidos via `wfdb` a $f_s = 360$ Hz:

- **ECG de referência (“limpo”)**: registros do mitdb (100, 103, 105, 115, 215).
- **Ruído fisiológico real**: registros do nstdb — bw (*baseline wander*), ma (*muscle artifact*) e em (*electrode motion*).

3.2 Contaminação controlada e métricas

O “coração” do protocolo é gerar pares (**limpo, contaminado**) com SNR conhecido, somando ao ECG limpo um ruído escalado para um SNR alvo:

$$x_{\text{ruidoso}} = x_{\text{limpo}} + k n, \quad k = \sqrt{\frac{P_{\text{limpo}}}{P_n \cdot 10^{\text{SNR}/10}}}.$$

Os **SNRs alvo** são **0, 6, 12 e 18 dB** (src/noise/contaminate.py). Como o sinal limpo é conhecido, calculam-se métricas objetivas (src/metrics/metrics.py):

Métrica	Definição	Interpretação
SNR (dB)	$10 \log_{10}(P_{\text{sinal}}/P_{\text{ruído}})$	quanto maior, melhor
Δ SNR (dB)	$\text{SNR}_{\text{saída}} - \text{SNR}_{\text{entrada}}$	ganho real do filtro
RMSE	$\sqrt{(x_{\text{ref}} - \hat{x})^2}$	erro absoluto
PRD (%)	$100 \sqrt{\sum (x_{\text{ref}} - \hat{x})^2 / \sum x_{\text{ref}}^2}$	distorção relativa
Correlação	Pearson entre x_{ref} e $\hat{x}$	fidelidade morfológica

3.3 Conjunto de filtros avaliados

Filtro	Tipo	Princípio	Parâmetros
Notch 60 Hz	IIR (biquad)	rejeição de banda estreita em f_0	$Q = f_0/\text{BW} = 30$, BW ≈ 2 Hz
Passa-alta 0,5 Hz	IIR Butterworth	magnitude maximamente plana	2ª ordem, filtfilt
Passa-baixa 40 Hz	FIR fase linear	janela de Hamming (lóculo ≈ -41 dB)	61 taps, atraso $(M-1)/2 = 30$ amostras
LMS	adaptativo FIR	gradiente do erro instantâneo	$\mu = 0,005-0,01$; $M = 5-10$
NLMS	adaptativo FIR	passo normalizado pela energia da entrada	$\mu = 0,01-0,02$; $M = 5-10$
DWT	wavelet	db4 + <i>soft-threshold</i> (Donoho & Johnstone)	níveis 5–9
CNN-DAE	rede neural (aprendida)	encoder–bottleneck–decoder convolucional 1-D	janela 1024, ~MAE, Adam; ver Parte III

3.4 Dois cuidados de protocolo (validados em dados reais)

1. **Atraso de grupo do FIR causal.** O FIR passa-baixa causal (lfilter) desloca o sinal em $(M-1)/2 = 30$ amostras; comparar a saída crua contra o clean dá correlação ≈ 0 e SNR enganosamente ruim. **Avalia-se o FIR em fase-zero** (filtfilt) ou compensa-se o atraso antes das métricas. Filtros filtfilt/IIR não têm esse problema.
2. **Referência para a deriva de linha de base.** O ECG do mitdb já contém conteúdo $< 0,5$ Hz; ao avaliar o passa-alta contra bw, compara-se contra uma referência **também passa-alta** (ref = apply_highpass(clean)), senão o filtro é penalizado por remover conteúdo legítimo do próprio sinal limpo.

Nota sobre comparabilidade entre as frentes. Os filtros convencionais (Parte I) foram avaliados com o protocolo de contaminação controlada acima (ruído **real** do nstdb em SNRs alvo).

Os filtros avançados (Parte II) foram avaliados sobre registros reais do mitdb contaminados com ruído **sintético** específico de cada caso (senoide de 60 Hz, senoide de 0,2 Hz e ruído gaussiano), em janelas de 5 s, usando uma referência adequada a cada método. A técnica inteligente (Parte III) tem **protocolo próprio, mais amplo**: treino/teste sobre os **48 registros** do mitdb com *holdout* por registro (10 registros nunca vistos), ruído real (bw/ma/em) e sintético (60hz/50hz), em janelas de 1024 amostras ($\approx 2,84$ s). As condições das três frentes são **relacionadas, mas não idênticas**; por isso a comparação entre frentes é qualitativa (qual método é robusto a qual ruído), e não um confronto numérico direto de SNR. O único ponto de contato numérico explícito é a avaliação estatística da Parte III, que testa a CNN-DAE **contra a tabela de referência dos convencionais** (*comparacao_convencionais.csv*) via teste de Wilcoxon.

Parte I — Filtros Convencionais

Validados sobre o registro 100 do mitdb com o protocolo de contaminação controlada (*scripts/gerar_figuras.py*). Os números desta parte vêm de *figures/comparacao_convencionais.csv*.

4.1 Notch IIR de 60 Hz

Filtro de rejeição de banda estreita (≈ 2 Hz) centrado em 60 Hz, com $Q = f_0/BW = 30$, removendo a rede sem degradar o QRS. O diagrama de polos/zeros mostra os zeros sobre a circunferência unitária no ângulo correspondente a 60 Hz e os polos imediatamente internos, o que estreita a banda de rejeição.




Figure 1: Notch 60 Hz — polos/zeros, $|H(e^jw)|$ e atraso de grupo

Figura 4.1 — Formalização do notch de 60 Hz: diagrama de polos/zeros, resposta em magnitude e atraso de grupo.




Figure 2: Notch 60 Hz — antes/depois (tempo + FFT)

Figura 4.2 — Efeito do notch no tempo e no espectro: o pico de 60 Hz é eliminado preservando a morfologia do QRS.

Resultados. O notch leva o sinal a $\approx 34,6$ dB de SNR de saída independentemente do nível de contaminação de entrada, com **PRD $\approx 1,87$ %** e **correlação 0,999** — praticamente recuperação perfeita do ECG.

SNR entrada (dB)	SNR saída (dB)	Δ SNR (dB)	PRD (%)	Corr.
0	34,57	+34,57	1,87	0,999
6	34,57	+28,57	1,87	0,999
12	34,57	+22,57	1,87	0,999
18	34,57	+16,57	1,87	0,999

4.2 Passa-alta IIR Butterworth de 0,5 Hz

Corrige a variação da linha de base preservando o segmento PR e o QRS; a resposta de magnitude maximamente plana do Butterworth evita ondulação na banda de passagem. Aplicado com `filtfilt` (fase zero). Avaliado contra a referência passa-alta (cuidado de protocolo nº 2).




Figure 3: Passa-alta 0,5 Hz — formalização

Figura 4.3 — Formalização do passa-alta Butterworth de 0,5 Hz.




Figure 4: Passa-alta 0,5 Hz — antes/depois

Figura 4.4 — Remoção da deriva de linha de base: a oscilação lenta é eliminada e a linha de base fica estável.

Resultados. O passa-alta entrega Δ SNR $\approx$ +18,6 dB consistente em todos os níveis de entrada, com a correlação subindo de 0,975 a 1,000 conforme o ruído de entrada diminui — é o filtro **certo** para *baseline wander*.

SNR entrada (dB)	SNR saída (dB)	Δ SNR (dB)	PRD (%)	Corr.
0	12,85	+18,64	22,77	0,975
6	18,85	+18,64	11,41	0,994
12	24,85	+18,64	5,72	0,998
18	30,85	+18,64	2,87	1,000

4.3 Passa-baixa FIR Hamming de 40 Hz

Atenua o ruído muscular de alta frequência; a janela de Hamming oferece atenuação de lóbulo lateral de ≈ -41 dB. FIR de fase linear $\rightarrow$ atraso de grupo constante de 30 amostras; avaliado em **fase-zero** (cuidado de protocolo nº 1).




Figure 5: Passa-baixa FIR 40 Hz — formalização

Figura 4.5 — Formalização do FIR passa-baixa de 40 Hz: note a fase linear e o atraso de grupo constante.




Figure 6: Passa-baixa FIR 40 Hz — antes/depois

Figura 4.6 — Contra ruído muscular de banda larga, a melhoria visível é pequena: o ruído ocupa a mesma faixa do ECG.

Resultados. Contra ruído muscular (ma) e de eletrodo (em), de banda larga, o passa-baixa de 40 Hz **praticamente não melhora o SNR ($\Delta \approx 0$ dB, chegando a levemente negativo)** — porque o ruído ocupa a mesma faixa do ECG. A correlação melhora com o SNR de entrada, mas o ganho de filtragem é nulo. **Esta é a limitação central dos filtros convencionais que motiva os filtros avançados** (Parte II).

Ruído	SNR entrada		Δ SNR (dB)	PRD (%)	Corr.
	(dB)	SNR saída (dB)			
ma	0	0,09	+0,08	99,08	0,467
ma	6	6,02	+0,03	49,99	0,722
ma	12	11,80	-0,19	25,71	0,897
ma	18	17,01	-0,98	14,11	0,966
em	0	-0,01	-0,00	100,14	0,462
em	6	5,93	-0,06	50,52	0,719
em	12	11,71	-0,28	25,97	0,895
em	18	16,94	-1,05	14,23	0,965

4.4 Síntese da Parte I

Ruído	Filtro adequado	Resultado típico
60 Hz (rede)	Notch IIR	SNR saída $\approx 34,6$ dB · PRD 1,9 % · corr 0,999
Deriva (bw)	Passa-alta Butterworth	Δ SNR $\approx +18,6$ dB consistente · corr $\rightarrow 1,0$
Muscular (ma/em)	Passa-baixa FIR (insuficiente)	Δ SNR ≈ 0 dB — motiva os avançados

Parte II — Filtros Avançados (dados reais MIT-BIH)

Análise das três técnicas — **LMS**, **NLMS** e **DWT** — aplicadas a registros reais do MIT-BIH, cada um contaminado com o ruído característico de cada caso, em janelas de 5 s (1800 amostras). A referência de cada filtro adaptativo é escolhida conforme a natureza do ruído:

- **60 Hz:** referência senoidal sintética em 60 Hz (frequência conhecida — caso clássico de cancelamento de ruído com referência);
- **0,2 Hz:** referência senoidal em 0,2 Hz (frequência respiratória / *wander*);
- **Gaussiano/EMG:** sem frequência conhecida $\rightarrow$ usa-se uma *delay-line* do próprio sinal ($D = 5$ amostras), abordagem que só funciona bem quando o ruído tem correlação temporal.

(As figuras desta parte são geradas em `notebooks/ reais.ipynb` e consolidadas em `notebooks/resultados.ipynb`.)

5.1 Caso 1 — Ruído de 60 Hz (Registro 100)

O ruído. Interferência da rede elétrica (EMI), determinística e periódica. Como o QRS tem componentes predominantemente abaixo de 40 Hz, a senoide de 60 Hz se sobrepõe ao sinal e pode mascarar o segmento ST e dificultar a medição do intervalo QT. O registro 100 bruto já evidencia um nível de ruído de alta frequência sobreposto à linha de base, visível como uma textura “granulada” entre os complexos QRS.




Figure 7: ECG bruto — Registro 100 (4 s)

Figura 5.1 — Sinal bruto do registro 100 (MIT-BIH): textura de ruído de alta frequência sobre a linha de base.

Domínio do tempo. Os três métodos preservam bem a morfologia do QRS. LMS e NLMS ficam praticamente sobrepostos ao original, com leve atenuação da textura de alta frequência; a DWT produz a linha de base visivelmente mais suave.

Figura 5.2 — Registro 100 + ruído de 60 Hz: original e saída de cada filtro (LMS, NLMS, DWT).

Espectro (FFT). A energia fisiológica concentra-se abaixo de ~ 40 Hz, com cauda de ruído além de 120 Hz. A DWT é a que mais atenua a energia acima de 40–60 Hz.




Figure 8: Comparação 60 Hz — tempo

Figura 5.3 — Espectro antes/depois da filtragem (caso 60 Hz).

Convergência dos pesos. Os pesos de LMS e NLMS ($M = 5$) oscilam em torno de zero, estáveis; picos transitórios coincidem com os instantes de QRS (o filtro reage ao QRS como “erro” a corrigir). O NLMS oscila com menor amplitude, reflexo da normalização.

Figura 5.4 — Evolução dos pesos adaptativos (LMS e NLMS) no caso de 60 Hz.

SNR.

Filtro	SNR (dB)
LMS	28,1
NLMS	31,0
DWT	29,6

Desempenho elevado e comparável nos três, com o NLMS levemente superior — coerente com o caráter quase periódico do ruído de rede.

5.2 Caso 2 — Deriva de Linha de Base / 0,2 Hz (Registro 101)

O ruído. *Baseline wander* de origem respiratória (~0,15–0,5 Hz), que desloca o ST e dificulta a análise do intervalo PR e a detecção do pico R.

Domínio do tempo. Aqui a diferença entre métodos é gritante. O **LMS** “achata” agressivamente a linha de base, mas **introduz distorções nas ondas T e overshoot negativo após o QRS** — ou seja, remove conteúdo de baixa frequência que pertence ao próprio ECG. O **NLMS** é pior: amplifica os picos R (de ~1,1 mV para até ~1,5 mV) e fica instável. A **DWT** é a única que preserva fielmente as ondas T e P, mantendo a linha de base praticamente idêntica à original.

Figura 5.5 — Registro 101 + deriva de 0,2 Hz: o NLMS amplifica os picos R (~1,5 mV) enquanto a DWT preserva a morfologia.

Espectro (FFT, 0–10 Hz). Após LMS/NLMS o pico próximo de 0 Hz é reduzido, mas **surgem picos espúrios** (~0,5/0,8/2,2 Hz) que não existiam — evidência espectral direta da distorção. O espectro pós-DWT é quase indistinguível do original.

Figura 5.6 — Espectro 0–10 Hz: picos espúrios surgem após LMS/NLMS; pós-DWT ~ original




Figure 9: FFT 60 Hz — antes/depois




Figure 10: Convergência dos pesos — 60 Hz




Figure 11: Comparação 0,2 Hz — tempo

Domínio do tempo. Com a referência *delay-line*, LMS e NLMS **amplificam fortemente os picos R** (de ~1,8 mV para 2,0–2,2 mV) e introduzem oscilações maiores — em vez de suavizar, “espetam” o sinal (o NLMS chega a picos negativos de –2,2 mV). A DWT preserva fielmente QRS, P e T, com leve suavização da linha de base.

Figura 5.8 — Registro 103 + ruído gaussiano: LMS/NLMS (*delay-line*) amplificam os picos R; a DWT preserva a forma de onda.

Convergência dos pesos. Aqui os pesos **não oscilam em torno de zero**: $w[0]$ cresce de forma quase monotônica (LMS até ~0,3; NLMS até ~0,45) — *drift* sem estabilização. O filtro está, na prática, virando um **preditor linear** do ECG (aprende a prever a próxima amostra), não removendo ruído gaussiano: sintoma de referência *delay-line* mal correlacionada com ruído verdadeiramente aleatório.

Figura 5.9 — Deriva (*drift*) dos pesos com referência *delay-line*: o filtro vira um *preditor linear*, não um cancelador de ruído.

SNR.

Filtro	SNR (dB)
LMS	4,6
NLMS	2,0
DWT	30,8

A DWT é amplamente superior (30,8 dB) — sem referência correlacionada, o cancelamento adaptativo perde sua premissa fundamental.

5.4 Comparação geral dos avançados (SNR)




Figure 12: FFT 0,2 Hz — antes/depois




Figure 13: Convergência dos pesos — 0,2 Hz



Figure 14: Comparação Gaussiano — tempo




Figure 15: Convergência dos pesos — Gaussiano

Tipo de ruído	LMS (dB)	NLMS (dB)	DWT (dB)
60 Hz	28,1	31,0	29,6
0,2 Hz	1,9	1,2	29,5
Gaussiano	4,6	2,0	30,8




Figure 16: Comparação geral de SNR — dados reais

Figura 5.10 — SNR por filtro e tipo de ruído (dados reais MIT-BIH): a DWT é a única consistente nos três cenários.

Padrão central da Parte II:

- **A DWT é o único método consistentemente eficaz nos três cenários** (~29,5–30,8 dB), independentemente do tipo de ruído e **sem precisar de referência externa**.
- **LMS/NLMS só funcionam bem quando há uma referência fisicamente correlacionada e bem definida em frequência** (60 Hz). Com referência aproximada (0,2 Hz) ou substituta (*delay-line*), o desempenho cai para $\text{SNR} \lesssim 5$ dB (sem ganho prático).
- **Entre LMS e NLMS não há vencedor consistente**: o NLMS supera no caso 60 Hz, mas é pior nos outros dois — a normalização pela energia amplifica o erro quando a referência não é informativa.

Parte III — Técnica Inteligente: CNN-DAE

A terceira frente é a resposta direta à limitação central das Partes I e II: nenhum filtro linear único trata bem **todas** as classes de ruído, e os mais simples (passa-baixa, adaptativo sem referência) falham contra ruído de banda larga sobreposto ao ECG. A proposta é um *denoising autoencoder* convolucional (CNN-DAE) — **um único modelo não linear, aprendido dos dados**, que recebe uma janela de ECG ruidoso e devolve a janela limpa, qualquer que seja o tipo de ruído.

É um **subprojeto independente** (`cnn-dae/`), sem dependência do código das Partes I/II: tem o próprio `data_io` (cobrindo os **48 registros** do `mitdb`, não apenas 5), o próprio módulo de contaminação (5 tipos de ruído, SNR contínuo) e o próprio pipeline de dados. O treino é feito no Google Colab (GPU T4) pelos notebooks `treino_cnn_dae.ipynb` / `validacao_cnn_dae.ipynb` / `avaliacao_cnn_dae.ipynb`.

6.1 Arquitetura

Rede totalmente convolucional 1-D no formato **encoder** → **bottleneck** → **decoder**, com entrada e saída de mesma forma (1024, 1) (janelas normalizadas por z-score). Os blocos do encoder são Conv1D → BatchNorm → ReLU; os do bottleneck e do decoder são **blocos residuais** (saída = $F(x) + x$), que fazem a rede aprender apenas a *diferença* entre o ruidoso e o limpo — isto é, o próprio ruído a remover.

Estágio	Operação	Resolução (amostras)	Filtros	Kernel
Entrada	—	1024	1	—
Encoder E1	Conv-BN-ReLU + MaxPool/2	1024 → 512	64	7
Encoder E2	Conv-BN-ReLU + MaxPool/2	512 → 256	128	5
Encoder E3	Conv-BN-ReLU + MaxPool/2	256 → 128	256	3
Encoder E4	Conv-BN-ReLU + MaxPool/2	128 → 64	256	3
Bottleneck	2 × bloco residual	64	512	3
Decoder D1	UpSampling×2 + residual	64 → 128	256	3
Decoder D2	UpSampling×2 + residual	128 → 256	128	3
Decoder D3	UpSampling×2 + residual	256 → 512	64	5
Decoder D4	UpSampling×2 + residual	512 → 1024	32	7
Saída	Conv1D 1×1 (linear)	1024	1	1

Decisões de projeto e seus porquês:

- **Kernels grandes nas bordas, pequenos no centro.** Campo receptivo amplo (7/5) na resolução original capta morfologia do batimento; kernels menores (3) onde a resolução já é baixa.
- **Conexões residuais.** Como o sinal limpo é quase igual à entrada, aprender só a correção ($F(x)$) é mais fácil e estável, além de mitigar o gradiente desvanecente.
- **Saída linear.** O ECG tem valores negativos (onda Q, ST deprimido); ativação linear na última camada não os trunca.
- **Perda MAE, métrica MSE.** O MAE é robusto a *outliers* (batimentos ectópicos, artefatos); o MSE acompanha como proxy do SNR de reconstrução. Otimizador Adam, *learning rate* 10^{-3} .

6.2 Protocolo de dados (a contribuição metodológica mais forte)

Aqui está o salto de rigor em relação às Partes I/II, que usavam poucos registros e janelas curtas:

- **Cobertura total:** todos os **48 registros** do MIT-BIH.
- **Separação por registro (sem vazamento):** **38 registros** (100–219) para treino+validação e **10 registros** (220–234) reservados para teste — **nunca vistos no treino**. Dentro de cada registro de treino, os 80 % iniciais vão para treino e os 20 % finais para validação (corte temporal). Há *asserts* no código garantindo a disjunção treino/teste.
- **Cinco tipos de ruído em um só modelo:** real do NSTDB (bw, ma, em) + rede elétrica sintética (60hz, 50hz). O ruído real também é dividido temporalmente (80 % treino / 20 % teste), de modo que o modelo é testado em trechos de ruído inéditos.
- **SNR contínuo no treino:** cada janela é contaminada *on-the-fly* com um SNR sorteado uniformemente em **[−2, 20] dB**, tipo de ruído aleatório e fase/posição aleatórias — o modelo vê uma variedade praticamente infinita de condições, em vez de uma grade fixa.
- **SNR fixo no teste:** grade determinística **{0, 6, 12, 18} dB** (semente 2026), permitindo comparação direta com o protocolo das Partes I/II.

- **Janela de 1024 amostras** ($\approx 2,84$ s a 360 Hz), normalização z-score usando média/desvio do **sinal limpo** (a mesma transformação é aplicada ao par ruidoso/limpo, preservando a relação entre eles).

6.3 Treino

`model.fit` com até **150 épocas**, *batch* 32, 400 *steps*/época (≈ 12.800 janelas) e 100 *steps* de validação, alimentado por geradores `tf.data` que produzem pares contaminados indefinidamente. Os *callbacks* tornam o treino auto-regulado:

- **ModelCheckpoint** — salva o melhor modelo por `val_loss` (`best_model.keras`);
- **EarlyStopping** — interrompe após 15 épocas sem melhora e restaura os melhores pesos;
- **ReduceLROnPlateau** — reduz o *learning rate* pela metade após 7 épocas de estagnação (até 10^{-6});
- **TensorBoard** — registro das curvas.

As curvas de aprendizado (MAE/MSE $\times$ época) e exemplos de filtragem são gerados ao final do treino (`treino_cnn_dae.ipynb`, células 11–12).

6.4 Avaliação estatística

A força do subprojeto está na avaliação, bem mais rigorosa que a das partes anteriores. O notebook `avaliacao_cnn_dae.ipynb` roda o modelo treinado sobre **toda a grade ruído $\times$ SNR** dos 10 registros de teste e produz, **por janela**, o conjunto completo de métricas (`src/metrics/metrics.py`): SNR de saída, Δ SNR, RMSE, PRD, correlação, além de MAE/MSE. Sobre essa base por janela, calcula:

- **Estatística descritiva** por tipo de ruído e por SNR de entrada (média, mediana, desvio, quartis e percentis P05/P95) — não só a média, mas a *dispersão* do desempenho;
- **Taxa de falha** — percentual de janelas em que o modelo *piorou* o sinal (Δ SNR < 0), por condição;
- **Teste de Wilcoxon** (*signed-rank*) comparando a CNN-DAE com a **tabela de referência dos filtros convencionais** (`comparacao_convencionais.csv`), com *p-valor* e **tamanho de efeito** $r = Z/\sqrt{N}$ — o único confronto numérico direto entre as frentes;
- **Intervalos de confiança 95 % por bootstrap** ($B = 1000$ reamostragens) para PRD, correlação e Δ SNR médios de cada condição;
- **Análise de falha** — visualização das piores janelas (menor Δ SNR), para diagnosticar *em que morfologia* o modelo erra;
- **Boxplots** por ruído e por SNR, e exportação dos resultados (`resultados_por_janela.csv`, `wilcoxon_vs_baseline.csv`, `bootstrap_ic95.csv`).

Estado dos resultados quantitativos. O repositório versiona a **arquitetura, o pipeline e todo o arcabouço de avaliação** da CNN-DAE, mas **não inclui um checkpoint treinado** (`best_model.keras`) nem as figuras/CSVs de saída — os notebooks estão sem células executadas. Os números finais de SNR/ Δ SNR/PRD da CNN-DAE são obtidos ao executar `treino_cnn_dae.ipynb` (treino no Colab) seguido de `avaliacao_cnn_dae.ipynb`. Esta Parte III documenta, portanto, **o projeto e o protocolo de avaliação** da técnica inteligente; a consolidação numérica e a sua inserção nas tabelas comparativas da Seção 7 são o passo final imediato (ver Seção 8.2).

6.5 O que se espera da CNN-DAE (hipótese de trabalho)

Pela natureza do método — mapeamento não linear aprendido, treinado conjuntamente nas cinco classes de ruído e em ampla faixa de SNR — a expectativa, a ser **confirmada pelos números** após o treino, é:

- **Generalização única:** um só modelo cobrindo 60 Hz, deriva e EMG/gaussiano, sem troca de filtro nem referência externa — vantagem operacional clara sobre LMS/NLMS;
- **Ganho potencial no caso mais difícil (banda larga/EMG),** justamente onde o passa-baixa convencional fica em $\Delta \approx 0$ dB e os adaptativos falham;
- **Custo:** exige treino (GPU), dados rotulados (pares limpo/ruidoso) e é menos interpretável que um notch ou um Butterworth — o *trade-off* esperado de uma abordagem de aprendizado.

A avaliação da Seção 6.4 foi desenhada exatamente para **testar** essas hipóteses (inclusive a taxa de falha e o Wilcoxon contra o baseline), e não apenas para reportar uma média favorável.

7. Comparação geral do projeto (convencionais × avançados × inteligente)

Cruzando as três frentes, emerge uma divisão de trabalho clara por tipo de ruído:

Ruído	Convencional	Avançado clássico	Inteligente (CNN-DAE)	Leitura
60 Hz	Notch IIR — excelente ($\approx 34,6$ dB, corr 0,999)	LMS/NLMS/DWT — todos bons (28–31 dB)	coberto pelo modelo único (a confirmar)	Ruído de banda estreita: qualquer abordagem específica resolve ; o notch fixo é o mais simples e robusto.
Deriva (bw/0,2 Hz)	Passa-alta — excelente ($\Delta \approx +18,6$ dB)	DWT — excelente (29,5 dB); LMS/NLMS falham (1–2 dB)	coberto pelo modelo único (a confirmar)	Baixa frequência separável: passa-alta linear ou DWT ; adaptativos distorcem o ECG.
Muscular / Gaussiano (ma/em/EMG)	Passa-baixa FIR — falha ($\Delta \approx 0$ dB)	DWT — excelente (30,8 dB) ; LMS/NLMS falham	alvo principal do modelo (a confirmar)	Ruído de banda larga sobreposto ao ECG: DWT resolve ; a CNN-DAE é a aposta de generalização num só modelo.
Todos juntos	troca de filtro por ruído	troca de método por ruído	um único modelo para os 5 tipos	A CNN-DAE é a única abordagem não especializada por ruído — sua vantagem operacional.

(A coluna CNN-DAE registra o papel projetado; os números entram após o treino — ver Parte III, Seção 6.4.)

Conclusões transversais:

1. **Para ruído de banda estreita e bem localizado (60 Hz)**, o filtro mais simples já basta: o notch IIR convencional iguala ou supera os avançados, com custo computacional mínimo.
2. **Para a deriva de linha de base**, o passa-alta linear e a DWT são as escolhas seguras; os adaptativos LMS/NLMS, apesar de “atacarem” a baixa frequência, **distorcem a morfologia** (ondas T/P, *overshoot*) — risco inaceitável em contexto clínico.
3. **Para o ruído muscular/gaussiano de banda larga**, onde o passa-baixa convencional fracassa ($\Delta \approx 0$ dB), **a DWT é o salto de qualidade do projeto**, recuperando ~ 30 dB sem referência externa. Esse é exatamente o cenário que justifica investir nos filtros avançados.
4. **A escolha do sinal de referência é o fator mais determinante para LMS/NLMS**. Eles brilham quando a referência captura a física do ruído (60 Hz) e se tornam inúteis — ou nocivos — quando a referência é uma aproximação ou um substituto.
5. **A CNN-DAE muda o eixo do problema**: em vez de escolher *um filtro por ruído*, propõe **um modelo para todos**. Troca conhecimento de projeto (polos/zeros, limiar wavelet, referência) por dados rotulados e treino. Se os números confirmarem a hipótese da Seção 6.5, ela é a forma mais geral de *denoising* do projeto; o custo é treino, dados e menor interpretabilidade.

8. Conclusões e trabalhos futuros

8.1 Conclusões

- O projeto cumpriu o objetivo de **projetar, validar e comparar** filtros convencionais, avançados clássicos e uma técnica inteligente para as três classes de ruído do ECG, com **métricas objetivas** sobre dados reais do PhysioNet.
- **Não existe um único “melhor filtro” clássico:** a escolha ótima depende do ruído. Em ordem de recomendação prática: **60 Hz** → **notch IIR**; **deriva** → **passa-alta Butterworth ou DWT**; **EMG/banda larga** → **DWT**.
- A **DWT** foi o método mais **robusto e de uso mais simples** entre os avançados clássicos (não exige referência, mantém alta fidelidade morfológica nos três ruídos).
- Os filtros **adaptativos LMS/NLMS** introduziram distorções relevantes (*overshoot*, amplificação de picos R) nos casos de baixa frequência e ruído aleatório — um risco em aplicações clínicas, onde a integridade da forma de onda é crítica para o diagnóstico.
- Os **gráficos de convergência dos pesos** foram úteis para *diagnosticar* a falha: nos casos problemáticos os pesos não estabilizam (seguem *drift* ou reagem ao QRS), sintoma direto de referência mal correlacionada.
- A **técnica inteligente (CNN-DAE)** foi **projetada e implementada por completo** — arquitetura residual convolucional, protocolo de dados rigoroso (48 registros, *holdout* por registro, 5 tipos de ruído, SNR contínuo) e um arcabouço de avaliação estatística (Wilcoxon vs. baseline, *bootstrap*, análise de falha) mais exigente que o das demais frentes. Falta apenas a execução do treino para consolidar os números (Seção 6.4) — é o único item pendente do projeto.

8.2 Possíveis melhorias futuras

- **Consolidar os resultados da CNN-DAE:** rodar `treino_cnn_dae.ipynb` no Colab, versionar o `best_model.keras`, executar `avaliacao_cnn_dae.ipynb` e inserir os números (SNR/ Δ SNR/PRD, Wilcoxon, IC *bootstrap*) nas tabelas comparativas da Seção 7.
- **Referências mais realistas para o EMG/gaussiano** (ex.: canal de eletrodo de referência dedicado, em vez de *delay-line*).
- **Ajuste sistemático de μ e M** (grid search) para LMS/NLMS nos casos de 0,2 Hz e gaussiano, hoje herdados do caso de 60 Hz.
- **Unificar os protocolos das três frentes** (mesmos registros, mesma contaminação real do nstdb, mesmos SNRs alvo) para um confronto numérico estritamente *head-to-head* entre convencionais, avançados clássicos e CNN-DAE.
- **DWT no caso de 60 Hz com nível de decomposição maior**, já que a FFT pós-DWT ainda mostrou energia residual acima de 40 Hz.
- **Variações da CNN-DAE:** comparar perdas (MAE $\times$ MSE $\times$ Huber), profundidade do *bottleneck* e janelas mais longas; e treinar uma variante por tipo de ruído para medir o custo de generalização do modelo único.

9. Reprodutibilidade

```
src/                                     # Partes I e II
  data_io.py                             # download/leitura mitdb+nstdb (wfdb, 360 Hz) – 5 registros
  noise/contaminate.py                   # contaminate(signal, noise_type, snr_db) – bw/ma/em/60hz
  filters/                               # notch 60Hz, passa-alta 0.5Hz, passa-baixa FIR 40Hz
  metrics/metrics.py                     # SNR/ $\Delta$ SNR/RMSE/PRD/correlação
  viz/plots.py                           # polos-zeros,  $|H(e^{j\omega})|$ , atraso de grupo, FFT, overlay
notebooks/
  01_dados, 02_filtros_convencionais, 03_demo      # convencionais (+ demo interativa)
  filtros, sintetico, reais, resultados            # avançados clássicos (LMS/NLMS/DWT)
scripts/gerar_figuras.py                  # gera figuras de formalização + comparacao_convencionais.csv
report/                                   # fontes LaTeX (introdução + fundamentação)
figures/                                  # figuras e tabela usadas neste relatório

cnn-dae/                                  # Parte III (subprojeto independente)
  src/data_io.py                           # 48 registros mitdb + nstdb
```

```

src/noise/contaminate.py# 5 tipos de ruído, SNR contínuo
src/models/dataset.py   # pools, splits sem vazamento, geradores, tabela de teste
src/models/model.py     # arquitetura CNN-DAE + callbacks
train.py               # treino por linha de comando
notebooks/             # treino / validacao / avaliacao (Colab T4)
checkpoints/           # best_model.keras (gerado pelo treino – não versionado)

# Partes I e II
python3.12 -m venv .venv && source .venv/bin/activate
pip install -r requirements.txt # pandas>=2.2.2 fixado
python -c "from src.data_io import ensure_datasets; ensure_datasets()" # baixa os dados
./venv/bin/python scripts/gerar_figuras.py # reproduz Parte I
# Parte II: executar notebooks/resultados.ipynb (roda filtros+sintetico+reais)

# Parte III (CNN-DAE) – local
cd cnn-dae && pip install -r requirements.txt
python train.py # treina (CPU/GPU)
# ou, no Colab (T4): treino_cnn_dae.ipynb → validacao_cnn_dae.ipynb → avaliacao_cnn_dae.ipynb

```

10. Referências principais

- Rangayyan, R. M.; Krishnan, S. *Biomedical Signal Analysis*, 3ª ed., Wiley, 2024.
- Challis, R. E.; Kitney, R. I. *The design of digital filters for biomedical signal processing* (parts 1–3), J. Biomedical Engineering, 1982–1983.
- Widrow, B. et al. *Adaptive noise cancelling: principles and applications*, Proc. IEEE, 1975.
- Thakor, N. V.; Zhu, Y.-S. *Applications of adaptive filtering to ECG analysis*, IEEE TBME, 1991.
- Donoho, D. L. *De-noising by soft-thresholding*, IEEE Trans. Information Theory, 1995.
- Singh, B. N.; Tiwari, A. K. *Optimal selection of wavelet basis function applied to ECG signal denoising*, Digital Signal Processing, 2006.
- Chiang, H.-T. et al. *Noise reduction in ECG signals using fully convolutional denoising autoencoders*, IEEE Access, 2019.
- Moody, G. B.; Muldrow, W. E.; Mark, R. G. *A noise stress test for arrhythmia detectors*, Computers in Cardiology, 1984 (nstdb).
- Goldberger, A. L. et al. *PhysioBank, PhysioToolkit, and PhysioNet*, Circulation, 2000.

(Bibliografia completa em report/referencias.bib.)